



Tarea 2: Máquina de Vectores Soporte y Técnicas de Manifold Learning para la Predicción de Churn en Spotify

Autores:

Daniel Fernández Magariños
Gabriel Carlos Suárez Chiquito

Fecha:

Enero 2026

Asignatura:

Aprendizaje Automático II

Índice

1	Introducción y Justificación	2
2	Sección I: Exploración Avanzada y Manifold Learning	2
2.1	Visualización con UMAP y t-SNE	2
2.2	Diagnóstico mediante Árboles de Decisión	2
3	Sección II: Desarrollo y Optimización del Modelo SVM	3
3.1	Preprocesamiento y Escalado	3
3.2	Selección de Características mediante RFECV	3
3.3	Optimización de Kernels e Hiperparámetros	3
4	Sección III: Comparativa de Resultados	3
5	Conclusión	4
	Apéndices	5

1. Introducción y Justificación

Tras los resultados obtenidos en la Tarea 1, donde los modelos lineales y las redes neuronales básicas mostraron un rendimiento similar al azar, este trabajo se plantea como una investigación técnica profunda sobre la naturaleza del dataset `paid_spotify.csv`. Nuestro objetivo no es simplemente el ajuste de hiperparámetros, sino la comprensión de la estructura subyacente de los datos para explicar por qué existe un "techo" de rendimiento tan marcado.

Para este análisis, se ha decidido trabajar exclusivamente con el subconjunto de usuarios con suscripción de pago. Como se detalla en el notebook, se eliminaron variables como `user_id` (por ser un identificador único sin valor predictivo) y variables como `paid`, `offline_listening` y `ads_listened_per_week`, ya que presentaban valores constantes para este grupo de usuarios, actuando únicamente como ruido en el entrenamiento de los modelos.

2. Sección I: Exploración Avanzada y Manifold Learning

La hipótesis principal de este trabajo es que las variables de comportamiento (tiempo de escucha, skips, etc.) no poseen suficiente señal para segregar las clases. Para verificar esto, aplicamos técnicas de reducción de dimensionalidad no lineal.

2.1. Visualización con UMAP y t-SNE

A diferencia de PCA, que busca maximizar la varianza global, técnicas como **t-SNE** y **UMAP** permiten capturar estructuras locales complejas. Al proyectar los datos a un espacio bidimensional (ver Figura 1 en el Apéndice 1), observamos lo que definimos como un ovillo o masa amorfa de datos. De estos resultados se observa que:

- No se detectan agrupamientos naturales que segreguen a los usuarios que abandonan (churn) de los que permanecen.
- El solapamiento es masivo en todas las proyecciones, lo que justifica por qué los modelos de la Tarea 1 fallaban: no existe un hiperplano ni una frontera no lineal clara en este espacio de características.

2.2. Diagnóstico mediante Árboles de Decisión

Complementamos este análisis con un Árbol de Decisión. Su función aquí no fue solo predictiva, sino diagnóstica. Al observar que el árbol necesita ramificarse excesivamente para encontrar nodos con baja entropía, confirmamos que no hay variables que expliquen el churn de forma directa.

Para este diagnóstico de entropía se utilizó un modelo con el hiperparámetro `min_samples_leaf` fijado a 25 (con un total de 3589 observaciones en el conjunto de entrenamiento), evitando así el ruido y sobreajuste de las hojas excesivamente pequeñas. El análisis reveló una estructura de alta fragmentación, donde clasificamos las hojas en tres categorías: Hojas Claras (16.07 % de los usuarios), Incertidumbre (31.25 %) y Tendencia con Ruido (52.68 %). Esto demuestra que para más de la mitad del dataset, las variables de comportamiento no permiten al modelo tomar una

decisión mejor que lanzar una moneda al aire. En el Apéndice 2 se detalla la justificación de esta restricción y el efecto del sobreajuste en modelos no controlados.

3. Sección II: Desarrollo y Optimización del Modelo SVM

3.1. Preprocesamiento y Escalado

Dado que las Máquinas de Vectores Soporte (SVM) son sensibles a la escala debido al uso de métricas de distancia, aplicamos `StandardScaler`. Esto asegura que variables con rangos amplios (como `listening_time`) no dominen sobre variables de ratio (como `skip_rate`).

3.2. Selección de Características mediante RFECV

Implementamos la técnica de **Eliminación Recursiva de Características con Validación Cruzada (RFECV)**. Este método evalúa la importancia de cada variable directamente con el estimador. Como se detalla en la Figura 5(a) del Apéndice 3, el algoritmo identificó que el rendimiento óptimo se alcanza con un subconjunto de **16 variables**.

Este método se aplicó sobre el modelo lineal debido a que permite una interpretación directa de los coeficientes. Una vez seleccionadas las 16 variables más importantes, se procedió a entrenar tanto el modelo lineal final como el modelo no lineal. Aunque el rendimiento con este subconjunto no difería drásticamente de usar el set completo, optar por 16 variables reduce significativamente la complejidad y el coste computacional.

3.3. Optimización de Kernels e Hiperparámetros

Se realizó *Grid Search* para el hiperparámetro C , que regula el balance entre el margen de error y la clasificación correcta. Evaluamos tanto kernels lineales como RBF (Radial Basis Function). A pesar de la capacidad teórica del kernel RBF para manejar datos no separables, los resultados (ver Tabla 1) muestran que no existe una ganancia significativa sobre el modelo lineal. Aplicando el principio de parsimonia, se selecciona el modelo lineal por su mayor interpretabilidad.

4. Sección III: Comparativa de Resultados

La Tabla 1 presenta el rendimiento consolidado de los modelos de la Tarea 2 frente a los de la Tarea 1.

Métrica	Tarea 1 (LR)	Tarea 1 (MLP)	Tarea 2 (SVM Lin)	Tarea 2 (SVM RBF)
Accuracy	0.5038	0.4859	0.5161	0.5052
Precision	0.2586	0.2435	0.2717	0.2551
Recall	0.5055	0.4810	0.5310	0.4869
F1-Score	0.3422	0.3233	0.3595	0.3348
AUC	0.4947	0.4781	0.4925	0.5067

Cuadro 1: Comparativa de figuras de mérito. Se observa que todos los modelos se sitúan cerca del 0.5 de AUC (azar).

5. Conclusión

Técnicamente, el trabajo confirma que el problema de predicción de churn en este dataset no se debe a la falta de complejidad del modelo, sino a la **ausencia de señal en los datos**. Ni las técnicas de manifold learning lograron encontrar una estructura de separación, ni las SVM con kernels no lineales pudieron superar la barrera del 50 % de AUC. Como recomendación futura, se sugiere la ingeniería de nuevas características o la inclusión de datos cualitativos.

Apéndices

Índice de Apéndices

1	Análisis de Dimensionalidad y Manifold Learning	6
2	Análisis de Sobreajuste en Árboles de Decisión	7
3	Optimización de Modelos y Selección de Características	8

Análisis de Dimensionalidad y Manifold Learning

Este apéndice detalla el comportamiento de los algoritmos de reducción de dimensionalidad. El objetivo de estas gráficas es demostrar visualmente que no existen clusters naturales que separen a los usuarios por su comportamiento.




Figura 1: Visualización UMAP del dataset completo. El color azul representa usuarios que no hacen churn y el naranja los que sí. Se observa una mezcla total de clases.

Para garantizar que el solapamiento no fuera un artefacto de una mala configuración de hiperparámetros, se realizaron barridos exhaustivos de sensibilidad tanto para UMAP como para t-SNE.




Figura 2: Sensibilidad de UMAP ante variaciones de vecinos ($n_neighbors$) y distancia mínima. Independientemente de los parámetros, no surge una separación de clases clara.

En estos resultados tampoco salían *clusters* naturales que separaran a los usuarios por otras variables categóricas (como el género, tipo de suscripción, etc.).




Figura 3: Visualización t-SNE variando el parámetro de perplejidad. Se confirma la estructura amorfa de los datos en distintos niveles de granularidad local.

Análisis de Sobreajuste en Árboles de Decisión

Para el diagnóstico de entropía se entrenó principalmente un árbol de decisión fijando el hiperparámetro `min_samples_leaf` a 25. Esta restricción impide que el árbol genere hojas con menos de 25 observaciones, actuando como un método de poda temprana para capturar tendencias más generales y evitar el ruido y el sobreajuste.

Como experimento comparativo, se entrenó un árbol de decisión sin fijar este hiperparámetro (permitiendo hojas de tamaño 1). Los resultados confirmaron que el modelo necesitaba ramificarse de forma extrema para intentar capturar la variabilidad de los datos. Como se observa en la Figura 4, esto deriva en un rendimiento excelente en el conjunto de entrenamiento pero muy deficiente en el conjunto de test, confirmando un sobreajuste debido a la falta de patrones reales en las variables disponibles.




Figura 4: Comparativa de figuras de mérito en entrenamiento y test para el árbol de decisión sin restricciones de profundidad. La diferencia entre figuras de mérito evidencia el sobreajuste.

Optimización de Modelos y Selección de Características

En esta sección se presentan las curvas de rendimiento utilizadas para la selección del modelo final y su configuración óptima.




Figura 5: Procesos de optimización: (a) La curva de RFECV muestra que el rendimiento máximo se estabiliza con 16 características (para la SVM con kernel lineal). (b) Búsqueda de C para el modelo SVM RBF, encontrando el máximo en validación con $C=0.1$.