
Grupo 3

Daniel Fernández Magariños y Gabriel Carlos Suárez Chiquito

Memoria Tarea 1

Introducción

Para abordar de una manera más sencilla y cómoda este trabajo, hemos decidido hacer un esquema del *workflow* que vamos a seguir descrito en el [Anexo I](#).

Objetivos

Nuestro *dataset* recoge datos de clientes de Spotify, con variables continuas (tiempo de escucha, anuncios escuchados...), categóricas (país, tipo de dispositivo...) y binarias, cómo es el caso de la variable objetivo, **churn**. Nuestro objetivo es entender los datos y entrenar un modelo que sea capaz de predecir los clientes que harán *churn*. Cabe destacar que la interpretación de *churn* es diferente según el cliente. Para los clientes que pagan algún tipo de suscripción, *churn* significa que dejan de pagar la suscripción, pero para los clientes que sólo usan Spotify sin pagar, *churn* significa que dejan de utilizar esta plataforma.

Debido a estas razones, nos planteamos dos opciones:

- Entrenar un modelo con los datos tanto de clientes que pagan y que no (datos globales).
- Entrenar dos modelos, uno para los clientes que pagan, y otro para los que no.

La ventaja de la primera opción es que es más sencillo, pero la desventaja es que estamos asumiendo que la variable objetivo es igual para todas las observaciones, cuando realmente no es así. Durante el trabajo probaremos ambas opciones, viendo las diferencias de rendimiento.

Sección 1

En esta primera sección abordamos el proceso de hacer un Análisis Descriptivo Exploratorio o *Exploratory Data Analysis* (EDA) y el preprocesamiento de los datos para que sea más sencillo trabajar con ellos.

En la primera parte del EDA, hemos comprobado que los datos estén bien. Mirando si hay valores nulos, valores atípicos (*outliers*) mediante técnicas gráficas de las distribuciones de las variables. No hemos visto ningún dato extraño, ni nulo. El único resultado destacable es la distribución de la variable de **anuncios escuchados por semana**, que explicamos en el [Anexo II](#).

En la segunda parte del EDA nos dedicamos a ver las relaciones entre nuestras variables. Para las variables continuas usamos como medida de relación la **correlación de Pearson**, que mide la correlación lineal entre pares de variables continuas. Para pares de variables binarias, categóricas o continuas hemos decidido usar la **información mutua**, pero para ello, es importante discretizar las variables continuas. El número de cortes en la discretización lo hemos buscado para maximizar la información mutua con la variable objetivo. Se presenta la matriz de información mutua en el [Anexo III](#).

Viendo los resultados de las relaciones, podemos destacar que **no existen relaciones entre pares a simple vista de nuestras variables**, excepto alguna relación (que no es entre la variable objetivo y otra). Las únicas relaciones encontradas son:

- Todos los clientes que tienen un plan de pago (familiar, estudiante o *premium*) usan Spotify sin conexión y no escuchan ningún anuncio por semana. De aquí la razón de la distribución extraña de anuncios por semana.
- Todos los clientes que tienen el plan gratuito, usan Spotify con conexión y escuchan varios anuncios por semana.

Al final de esta sección realizamos el preprocesamiento necesario para poder entrenar modelos con nuestros datos. Usamos la **normalización Z** para las variables continuas y para las categóricas usamos dos tipos de codificaciones:

- Codificación **One-Hot Encoding** (OHE): es más simple de hacer cuando te llegan datos nuevos y se puede interpretar las nuevas variables creadas.
- Codificación **Target-Encoding** (TE): es más difícil de codificar datos nuevos sin sobreajustar y complica la interpretación de coeficientes en los modelos. Aún así, mejora el problema de la dimensionalidad de OHE.

Sección 2

En esta sección, tenemos el objetivo de entrenar el mejor modelo de **regresión logística** que podamos con nuestros datos. Para ello, probamos diferentes opciones, como es usar la codificación OHE o TE, usar diferentes tipos de regularización (*Ridge*, *Lasso* y *Elastic-Net*) y probar el modelo con diferentes combinaciones de nuestras variables (*stepwise selection*). Tras una búsqueda exhaustiva de estas opciones, comparando modelo a modelo, nuestra elección final es usar un **regresor logístico en los datos de OHE** (para la interpretabilidad, ya que la diferencia de rendimiento con el de TE era muy pequeña), **usando la regularización *Elastic-Net*** (ya que combina la *Ridge* y *Lasso*) y con pocas variables según el *dataset* que estemos usando (global, clientes de pago o clientes de no pago).

Hemos mencionado en la introducción, que íbamos a probar dos opciones, separando los datos en clientes de pago y no pago, o directamente usar los datos juntos. En el [Anexo IV](#), se muestra la comparación del rendimiento obtenido en esta sección haciendo ambas opciones. También se presentan las **curvas ROC** obtenidas en el [Anexo V](#) y los **odds ratio** en el [Anexo VI](#).

Aún así, es destacable decir que el rendimiento de los modelos obtenidos es similar al de un modelo aleatorio. La razón de esto es por la falta de relaciones en nuestras variables con la variable objetivo. Por esta razón, el aprendizaje de los modelos es pobre, ya que no aprende mucho de los datos de entrada.

Sección 3

En esta sección nos centramos en entrenar un modelo **Perceptrón Multicapa** (MLP o *Multi-Layer Perceptron*). Para entrenar estos modelos, hacemos uso del **grid search**, para buscar todos los hiperparámetros óptimos de la red neuronal. Vamos haciendo uso de las diferentes combinaciones de las codificaciones de OHE y TE con los diferentes *datasets* (global, de pago y no pago). En estas combinaciones también hacemos uso de gráficos que muestran la evolución del rendimiento del modelo según el número de iteraciones en el algoritmo *backpropagation* ([Anexo VII](#)).

Tras probar diferentes combinaciones e hiperparámetros, vemos que el aprendizaje de estas redes neuronales es muy inestable con la falta de relaciones y porque el algoritmo se topa con mínimos locales más fácilmente que el regresor logístico.

En casi todos los MLPs entrenados, vemos que siempre predicen las observaciones como clases positivas o negativas. Esto no sucedía en el regresor logístico, ya que este penaliza más las probabilidades extremas en el coste y este optimiza un coste convexo, por lo que es más fácil para él llegar al óptimo global, a diferencia del MLP, que es mucho más probable que llegue a un óptimo local, y aunque llegue a otro óptimo mejor, realmente aprende a predecir todo 0 ó 1, ya que para su coste es lo mejor. Esto se debe a que las **funciones de activación "permiten" probabilidades más extremas que en el regresor logístico**.

Sólomente hemos podido hacer **un modelo que tiene predicciones más estables**, es decir, que no predice todo a una clase. Este modelo fue entrenado con los datos globales (de pago y de no pago juntos) y codificados con OHE. El rendimiento de este MLP se muestra comparado con el del regresor logístico de los mismos datos (datos globales) en el [Anexo VIII](#).

En esta sección hemos hecho uso de la técnica **stepwise selection** sólomente para este último modelo, ya que los demás predecían todo a una clase, independientemente de las variables de entrada. El resultado de esta selección de características era quedarnos sólo con el ratio de omitir.


Sección 4

Hemos ido viendo durante las diferentes secciones, que el aprendizaje de los modelos es muy pobre, debido a la falta de relaciones de nuestras variables con la variable objetivo.

Aún así, hemos comparado el rendimiento entre los MLPs que hemos escogido (el más estable mencionado anteriormente) y los regresores logísticos elegidos (mostrados en el Anexo VII). Los regresores logísticos son más estables, ya que penalizan más predecir probabilidades tan extremas (como 0 ó 1). En el caso de los MLPs, el problema es que aunque en el coste también se penalice esto, la función de coste mitiga esta penalización, haciendo más probable la predicción extrema, de predecir todo a 0 ó 1.



Para un trabajo futuro, podríamos probar a hacer **transformaciones de las variables de entrada**, viendo a ver si así podemos recoger más información de la variable objetivo, y mejorando así, el aprendizaje de los modelos.

Otro aspecto en el que trabajar en el futuro sería en la **recogida de datos**. Podríamos probar a recoger diferentes variables de las que ya tenemos, viendo si estas guardan más información de la variable objetivo. Una alternativa si esto no funcionase sería recoger **datos temporales**. Ya que en los datos con los que hemos trabajado recogen medias de variables en el tiempo. Por ejemplo, estamos asumiendo la media de minutos escuchados, canciones escuchadas, anuncios escuchados... Podría ser muchísimo más útil recoger información de cada cliente durante el tiempo, ya que por ejemplo un cliente que haya usado muchísimo Spotify durante unos meses, y los dos últimos meses no lo escuche casi nunca, si no tenemos en cuenta el tiempo y hacemos la media nos saldrían valores altos, pero si tenemos en cuenta el tiempo, **podemos ver la evolución de este cliente**, que sería muy útil para predecir el *churn*.




Anexo I

Workflow a seguir en el trabajo. Se muestra que partimos de todos los datos. El siguiente paso es hacer el EDA, y como se explica dividimos los datos en tres datasets, uno con todos los datos originales, otro con los datos de clientes de pago y otro con los clientes con un plan gratuito. Luego para cada dataset aplicaremos varios modelos, comenzando con un regresor logístico sin regularización, seguido de uno con regularización. Después aplicaremos un método de selección de características (stepwise selection) para reducir la complejidad del modelo, y por último entrenaremos un MLP. Finalmente reunimos todos los resultados obtenidos comentando las conclusiones finales y trabajo futuro para mejorar.




Anexo II

Distribución de la variable de anuncios escuchados a la semana. Podemos ver que destaca la frecuencia de ceros que aparece. Esto es debido a que todos los clientes que pagan un tipo de suscripción no escuchan ningún anuncio.




Anexo III

Matriz de información mutua normalizada (rango entre 0 y 1). Vemos la falta de relaciones a pares de variables, especialmente entre la variable objetivo `is_churned` y las demás. Vemos algún valor alto que se explica a continuación.




Anexo IV

Rendimiento de las dos opciones (entrenar un sólo modelo para el dataset global o entrenar un modelo para cada dataset, de pago y de no pago). En la primera columna se muestran las figuras de mérito obtenidas si entrenamos un modelo a los datos globales, y en la segunda son las figuras de mérito medias (media entre las obtenidas en el dataset de pago y el dataset de no pago) haciendo la segunda opción. Vemos que realmente tenemos un rendimiento muy similar en ambas opciones. Por ello, se podría presentar ambas a Spotify, dejando que decidan qué hacer a ellos. Cabe destacar que vemos que el rendimiento es similar al de un modelo aleatorio (vemos el AUC con un valor de 0.5). Esto es por la falta de relaciones y el aprendizaje pobre de nuestros modelos.




Anexo V

Curvas ROC de los tres regresores logísticos finales elegidos para cada dataset, el global, de pago y de no pago. Vemos que ambos tienen un rendimiento muy parecido, aunque no es muy correcto comparar entre estos tres, ya que tienen datos diferentes (la unión de dos de ellos forma los datos del otro). También vemos que tienen una curva ROC muy parecida al modelo aleatorio, como ya se ha explicado anteriormente.




Anexo VI.a

Odds ratios del modelo con los datos globales. Vemos que tenemos cinco variables (seleccionadas por el stepwise selection), y vemos sus intervalos de confianza, diciéndonos cuánto podemos confiar en su interpretación. Podemos interpretar que los clientes austrianos y alemanes son más propensos a irse de Spotify. También vemos que cuánto mayor ratio de omitir (skip_rate) y canciones escuchadas al día, también los clientes son más propensos a irse. El ratio de omitir tiene sentido, pero las canciones escuchadas no tanto. Aún así, podría ser, ya que los clientes que usen más la aplicación a lo mejor se saturan más y se van antes. Por último, vemos que los clientes que usan Spotify en la web, son más propensos a quedarse. Sería interesante ver las diferencias e intentar entender el por qué de esto.




Anexo VI.b

Odds ratios del modelo con los datos de clientes de pago. Vemos que hay diferentes variables respecto al anterior. Según estos odds ratios podemos interpretar que cuántas más canciones escuchadas al día es más probable que se vaya de Spotify. También vemos que las personas mayores, que tienen un plan Premium y son de India son más propensas a quedarse.




Anexo VI.c

Según los odds ratio vemos que los clientes que tienen un mayor ratio de omitir y los alemanes son más propensos a irse de Spotify. También vemos que los clientes de Canadá, Australia, Pakistán y los que usan Spotify en la web son más propensos a quedarse (concuenda con lo que vimos en los datos globales).



Anexo VII

Evolución del F1-score en test respecto al número de épocas. Podríamos tener una confusión muy fácil, pensando que cuantas más épocas, mejor rendimiento. Esto no tiene por qué ser así. Tiene sentido que sea así si estuviésemos graficando el rendimiento medido en los datos de entrenamiento, pero estamos graficando el rendimiento medio obtenido con validación cruzada (CV). Por ello, no tiene por qué ser que cuantas más épocas, mejor rendimiento. De hecho, tiene sentido que no sea así, ya que normalmente cuantas más épocas, el modelo sobreajustará más, teniendo muy buen rendimiento en los datos de entrenamiento, pero peor en test. Por ello sale una línea descendente.



Anexo VIII

En la primera tabla se muestran las figuras de mérito para el regresor logístico para los datos globales (primera columna) y las figuras de mérito para el MLP “estable” de los datos globales. Vemos que tienen un rendimiento muy similar, aunque algo mejor el regresor logístico, y como este último es más sencillo, interpretable y estable, decidimos quedarnos con este como modelo final de estos datos globales. La segunda figura muestra las curvas ROC de estos dos modelos, viendo que el regresor logístico es algo mejor, porque está por encima.